Rust 2019

compscicenter.ru

aleksey.kladov@gmail.com

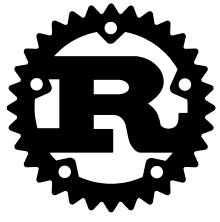

Лекция 7
Объекты, строки

impl Trait

Как вернуть итератор?

```
fn random(n: usize) -> Vec<u32> {
    let mut r = 92;
    std::iter::repeat_with(move || {
        r ^= r << 13;
        r ^= r >> 17;
        r ^= r << 5;
        r
    }).take(n).collect()
}
```

- не гибко — аллоцируем `Vec`

Как вернуть итератор?

```
fn random<T: FromIterator<u32>>(n: usize) -> T {
    let mut r = 92;
    std::iter::repeat_with(move || {
        r ^= r << 13;
        r ^= r >> 17;
        r ^= r << 5;
        r
    }).take(n).collect()
}
```

- лучше, но всё равно не удобно, не хочется думать про n

Как вернуть итератор?

```
fn random() -> ??? {
    let mut r = 92;
    std::iter::repeat_with(move || {
        r ^= r << 13;
        r ^= r >> 17;
        r ^= r << 5;
        r
    })
}
```

- написать конкретный тип не можем из-за лямбды
- написать `-> Iterator<Item = u32>` не получится — `Iterator` это не тип

Попытка 1

```
fn random<T: Iterator<Item = u32>>() -> T {
    let mut r = 92;
    std::iter::repeat_with(move || {
        r ^= r << 13;
        r ^= r >> 17;
        r ^= r << 5;
        r
    })
}
```

Попытка 1

- не работает: вызывающий код выбирает тип T:

```
struct MyIter;
impl Iterator for MyIter { type Item = u32; ...  }

fn main() {
    let _ = random::<MyIter>();
}
```

- "я могу вернуть **любой** T для котого верно `T: Iterator<Item = u32>`"
- нужно "**существует** какой-то `T: Iterator<Item = u32>`"

impl Trait

```
fn random() -> impl Iterator<Item = u32> {
    let mut r = 92;
    std::iter::repeat_with(move || {
        r ^= r << 13;
        r ^= r >> 17;
        r ^= r << 5;
        r
    })
}
```

- `-> impl Trait` не тип, синтаксис для ограниченного вывода типов (`-> auto` нет)
- генератор машинного кода знает конкретный тип, но вывод типов знает только про `: Trait`
- нельзя использовать в качестве типа поля

impl Trait

`impl Trait` можно использовать для аргументов, в качестве сахара для типовых параметров

```
fn process(items: impl Iterator<Item = Foo>) {

}

fn process<I: Iterator<Item = Foo>>(items: I) {

}
```

- аргумент: **forall**
- возвращаемое значение: **exists**

dyn Trait

```rust
trait Say {
    fn say(&self);
}

impl Say for Cat { ... }
impl Say for Dog { ... }

fn main() {
    let mut animals = Vec::new();
    animals.push(Cat::new("Garfield"));
    animals.push(Dog::new("The Hound of the Baskervilles"));
    for animal in animals.iter() {
        animal.say();
    }
}
```

- нельзя сложить `Cat` и `Dog` в вектор — разный тип и размер
- частично решили проблему в случае с функциями

Таблица Виртуальных Функций

В Java работает, потому что и `Cat`, и `Dog` — указатели:

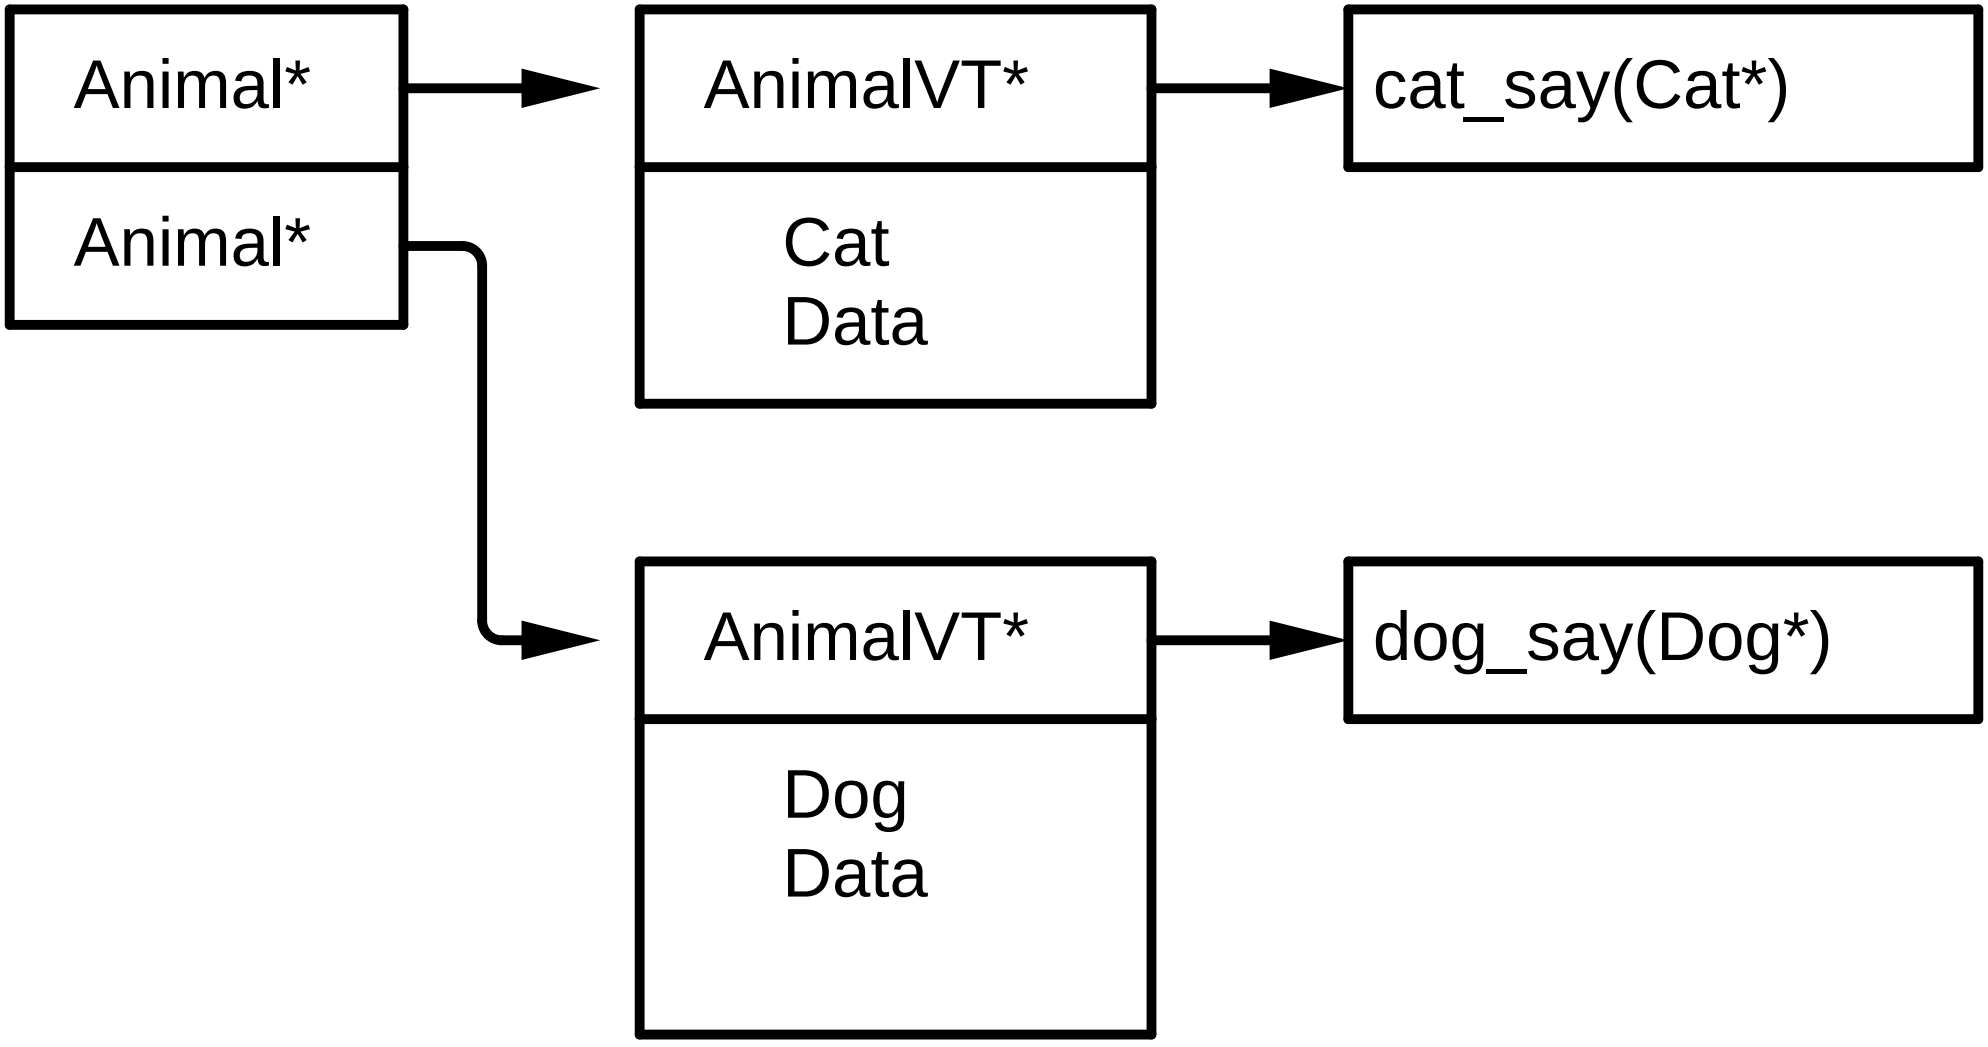

Таблица Виртуальных Функций

Объяснение на пальцах:

Таблица вируальных функций — структура из указателей на функции. Функции наследников записываются в конец.

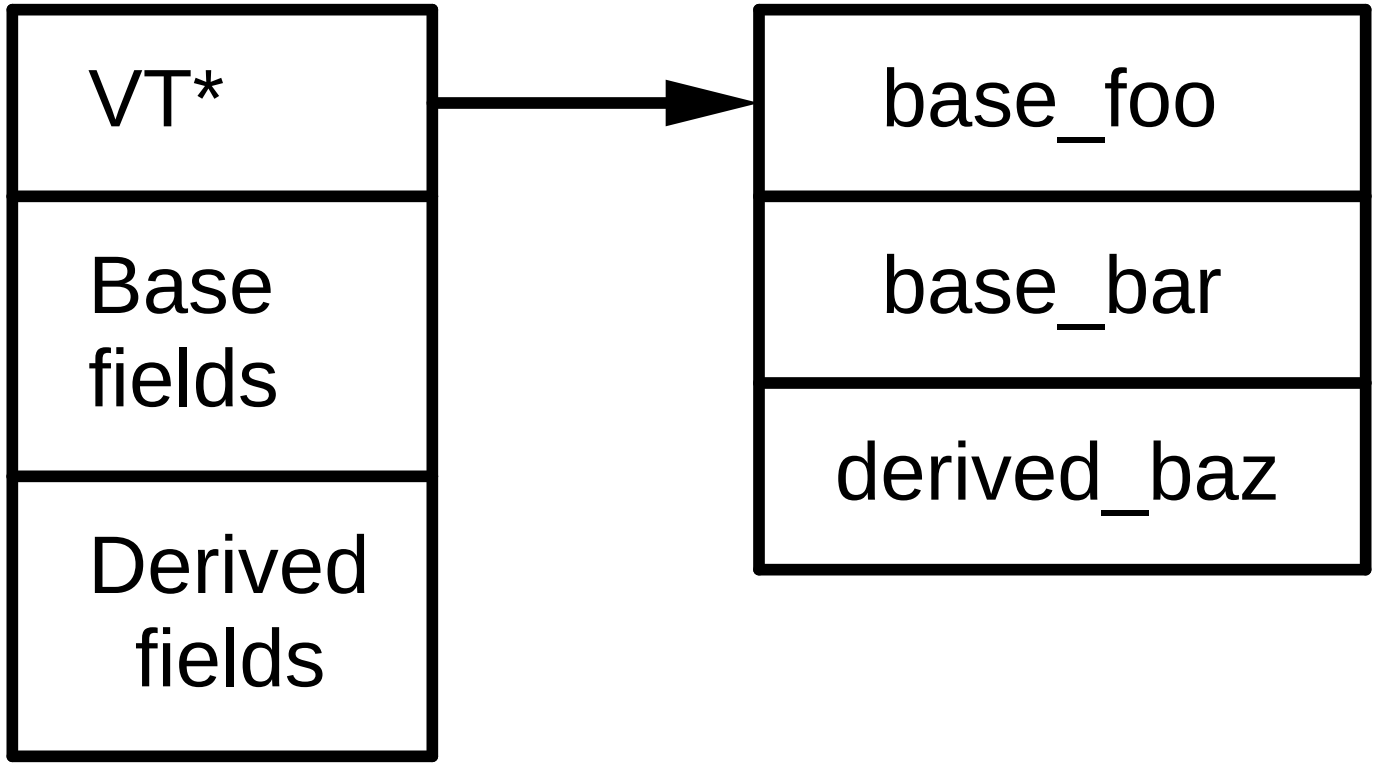

Таблица Виртуальных Функций

Как выглядит таблица виртуальных функций для класса с несколькими интерфейсами?

https://lukasatkinson.de/2018/interface-dispatch/

https://wiki.openjdk.java.net/display/HotSpot/VirtualCalls

https://wiki.openjdk.java.net/display/HotSpot/InterfaceCalls

Интерфейсы в C++

Внутри каждого объекта — несколько `vtable*` (по одной на каждый интерфейс).

Каст `Derived*` к `Base*` это coercion, значение указателя меняется.

Следствие:
Нельзя привести `vector<Derived*>` к `vector<Base*>`

Интерфейсы в Java

В Java, `List<Derived>` **можно** привести к `List<Base>`.

Вместо VTable — указатель на класс. В классе — список VTableов для каждого интерфейса. Для вызова метода интерфейса надо честно найти нужный интерфейс в списке.

JIT оптимистически всё инлайнит

thin pointer

VTable можно сложить в объект (C++, C#, Java):

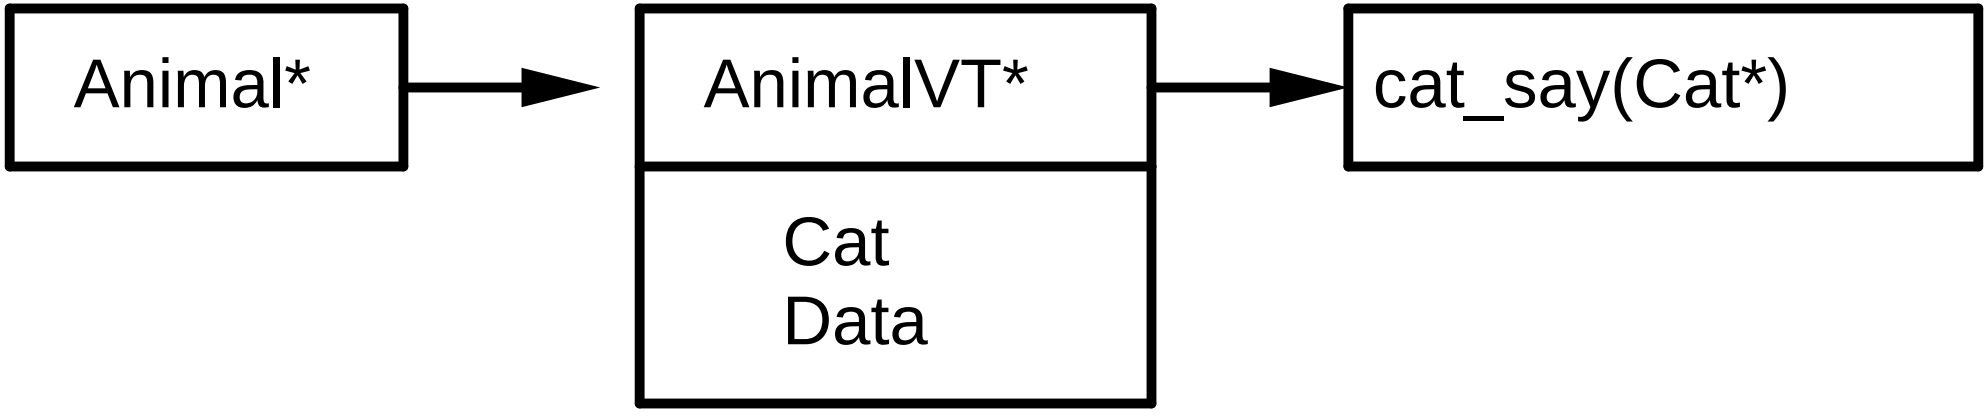

fat pointer

Но можно положить и рядом с указателем (Rust, Go):

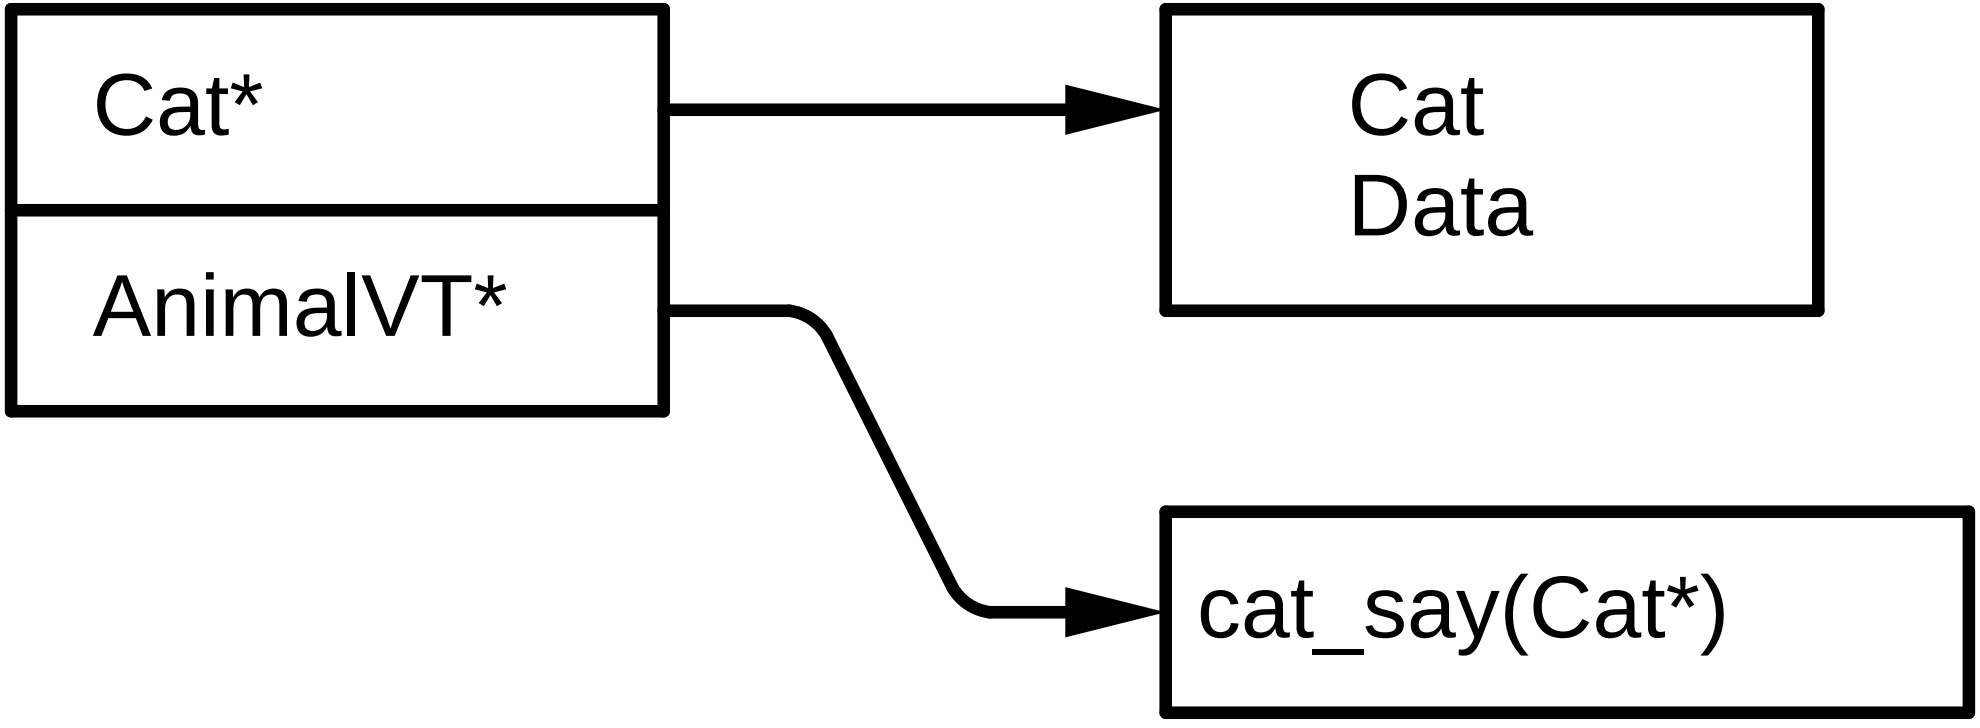

`dyn Trait`, trait object

Толстый указатель: пара из указателя на данные и указателя на таблицу виртуальных функций

```
trait Say {
    fn say(&self);
}

fn main() {
    let cat: Cat = Cat::new("Garfield");
    let cat: &dyn Say = &cat;
    let dog: Dog = Dog::new("The Hound of the Baskervilles");
    let dog: &dyn Say = &dog;
    let animals = vec![cat, dog];
    for animal in animals.iter() {
        animal.say();
    }
}
```

```rust
trait Say {
    fn say(&self);
}

impl Say for i32 {
    fn say(&self) {
        println!("hm... int-int?")
    }
}

fn main() {
    let i: i32 = 92;
    let i: &dyn Say = &i;
    let animals = vec![i];
    for animal in animals.iter() {
        animal.say();
    }
}
```

Замыкания часто используются с **dyn** `Trait`:

```
type Callback = Box<dyn Fn(u32) -> u32>;

fn adder(x: u32) -> Callback {
    Box::new(move |y| x + y)
}

fn multiplier(x: u32) -> Callback {
    Box::new(move |y| x * y)
}
```

`Box<dyn Fn(T) -> U>` — аналог `std::function`

dyn Trait

Трейты механизм и статического, и динамического полиморфизма

Dynamic dispatch работает для чужих типов

`dyn` `Trait` можно использовать с любым указателем:

```
size_of::<&dyn Say>()
  == size_of::<Box<dyn Say>>()
  == size_of::<*const dyn Say>()
  == size_of::<usize>() * 2
```

Dynamically Sized Types

`[T]` и **`dyn`** `Trait` это примеры DST: размер объекта не определяется статически. Обращение к DST — через толстый указатель.

Для не DST типов верно `: Sized`. Типовые параметры по умолчанию `Sized`

`std::mem`

```
fn size_of<T>() -> usize                    // неявный where T: Sized
fn size_of_val<T: ?Sized>(val: &T) -> usize // убрали ^
```

Dynamically Sized Types

```rust
pub trait Index<Idx: ?Sized> {
    type Output: ?Sized;

    fn index(&self, index: Idx) -> &Self::Output;
}

impl<T> Index<Range<usize>> for [T] {
    type Output = [T]; // unsized!
    fn index(&self, index: I) -> &[T]
}
```

на слайдах предыдущих лекций я не писал **`: ?Sized`**

Object Safety

Не из каждого трейта можно приготовить trait object

Нельзя возвращать/принимать `Self` по значению:

```
trait Clone {
    fn clone(&self) -> Self;
}
```

Нельзя использовать ассоциированные функции:

```
trait Default {
    fn default() -> Self;
}
```

Нельзя использовать параметризованные методы:

```
trait Hash {
    fn hash<H: Hasher>(&self, state: &mut H)
}
```

Когда Self: Sized

```
trait ObjectSafe {
    fn ok(&self);

    fn generic<T>(&self, t: T)
        where Self: Sized;

    fn bad_self() -> Self
        where Self: Sized;
}

fn foo(obj: &dyn ObjectSafe) {
    obj.ok();
    // the `generic` method cannot be invoked on a trait object
    // obj.generic::<i32>(92)
}
```

Только не `Self: Sized` методы определяют object safety

Iterator

```
trait Iterator {
    type Item;
    fn next(&mut self) -> Option<Self::Item>; // object safe

    fn map<B, F>(self, f: F) -> Map<Self, F> // object safe!
        where Self: Sized, F: FnMut(Self::Item) -> B,
    { Map { iter: self, f } }

    ...
}
```

Из итератора можно сделать `Box<dyn Iterator<Item = T>>`, аналог `Iterator<E>` из Java. Цена: аллокация в куче и dynamic dispatch на внешнем слое.

Iterator

```
fn with_any_iterator(it: &mut dyn Iterator<Item = u32>) {
    let first = it.next(); // ok, next is object safe
    let it = it.filter(|it| it > 100) // ???
}
```

На **dyn** `Iterator` можно позвать `.next`, но не понятно, что делать с комбинаторами:

```
fn filter_map<B, F>(self, f: F) -> FilterMap<Self, F>
    where Self: Sized, F: FnMut(Self::Item) -> Option<B>,
{ FilterMap { iter: self, f } }
```

Наш Self это &**mut dyn** `Iterator`

Iterator

```
impl<I: Iterator + ?Sized> Iterator for &mut I {
    type Item = I::Item;
    fn next(&mut self) -> Option<I::Item> { (
        **self).next()
    }
    fn size_hint(&self) -> (usize, Option<usize>) {
        (**self).size_hint()
    }
    fn nth(&mut self, n: usize) -> Option<Self::Item> {
        (**self).nth(n)
    }
}
```

dyn Iterator это : Iterator ⇒

&**mut dyn** Iterator — тоже : Iterator

Философия

Dynamic dispatch — мощный инструмент, вызов не известного кода

Отлично подходит для плагинов, но затрудняет понимание кода

Нарушает inline, требует косвенности ⇒ не супер быстрый

В целом, **`dyn`** `Trait` используется редко

Строки

std::fmt::Debug и std::fmt::Display

Трейты `Debug` и `Display` используются для превращения объектов в строки.

```
let text = "hello\nworld ";
println!("{}", text);   // Display
println!("{:?}", text); // Debug
```

```
$ ./main
hello
world
"hello\nworld "
```

`Display` для пользователя = `Debug` для программиста

```rust
#[derive(Debug)] // Debug можно реализовать автоматически
struct Foo {
    x: i32
}

fn main() {
    let xs = vec![Foo { x: 1 }, Foo { x: 2 }],
    eprintln!("{:?}", xs);
    eprintln!("{:#?}", xs); // # включает альтернативный формат
}
```

```
$ ./main
[Foo { x: 1 }, Foo { x: 2 }]
[
    Foo {
        x: 1
    },
    Foo {
        x: 2
    }
]
```

Дизайн

```rust
trait Display {
    fn fmt(&self, f: &mut fmt::Formatter) -> fmt::Result;
}
```

Возвращать `String` плохо:

- если выводим сразу в файл, то ненужная аллокация
- можно выводить в буфер на стеке ограниченного размера
- `N` отдельных аллокаций для подобъектов

Дизайн

Formatter абстрагирует назначение:

```
pub struct Formatter<'a> {
    flags: u32,
    fill: char,
    align: rt::v1::Alignment,
    width: Option<usize>,
    precision: Option<usize>,

    buf: &'a mut (dyn Write+'a), // trait object / NVI
    curarg: slice::Iter<'a, ArgumentV1<'a>>,
    args: &'a [ArgumentV1<'a>],
}

impl<'a> Formatter<'a> {
    fn write_str(&mut self, data: &str) -> fmt::Result;
    ...
}
```

ToString

```rust
pub trait ToString { (1)
    fn to_string(&self) -> String;
}

impl<T: fmt::Display + ?Sized> ToString for T {
    fn to_string(&self) -> String {
        use core::fmt::Write;
        let mut buf = String::new();
        buf.write_fmt(format_args!("{}", self)) (2)
           .expect("Display returned an error unexpectedly");
        buf.shrink_to_fit();
        buf
    }
}
```

(1) `ToString` — чтобы можно было позвать `.to_string`

(2) `format_args`: компилирует шаблон строки

String

Строки в Rust устроены просто:

```
pub struct String {
    vec: Vec<u8>,
}
```

Вектор байт + **инвариант**, что в байтах валидный UTF-8

UTF-8

Variable length encoding, совместима с ASCII, 1 байт для latin-1

```
a  : 0x61
ы  : 0xd1 0x8b
😀 : 0xf0 0x9f 0x98 0x80
```

UTF-8 — кодировка по умолчанию в современных системах

нет random access доступа к символу (в целом не понятно, что такое символ)

UCS-2 / UTF-16

В 1991 году думали, что 65536 символов хватит всем: UCS-2 это fixed width (16 бит) кодировка с random access.

Много систем изначально использовали UCS-2 (Java, Windows, JavaScript).

В 1996 UCS-2 расширили до `UTF-16`: пара суррогатных символов кодирует один code point вне BMP.

`UTF-16` — тоже variable length, не random access.

Многие языки используют UTF-16 с API UCS-2: можно получить невалидные данные в стоке.

API

```
impl String {
    fn new() -> String;
    fn with_capacity(capacity: usize) -> String; (1)
    fn from_utf8(vec: Vec<u8>) -> Result<String, FromUtf8Error>(2)
    fn from_utf16(v: &[u16]) -> Result<String, FromUtf16Error>(3)
    fn into_bytes(self) -> Vec<u8>;
}

impl FromUtf8Error {
    fn into_bytes(self) -> Vec<u8>(4)
}
```

1. строки изменяемые (если у вас есть &**mut**)
2. конверсия из UTF-8 не копирует
3. конверсия из UTF-6 копирует
4. в случае ошибки можно получить свой вектор назад

str

`str` — DST, `[u8]` + utf-8 инвариант.

`&str` — указатель на байты + размер, неизменяемая строка

```
impl Deref for String {
    type Target = str;
    ...
}

impl Index<Range<usize>> for String {
    type Output = str;
}
```

`&str` можно получить из `String` через слайс: `&s[1..10]`

Индексы для стайса — позиции в байтах

Если позиция приходится на середину символа — паника

Строки Без Копирования

```
impl str {
    fn split_whitespace<'a>(&'a self) -> SplitWhitespace<'a>;
}

impl<'a> Iterator for SplitWhitespace<'a> {
    type Item = &'a str;
    ...
}
```

Многие методы на `&String` `&str` возвращают `&str` — zero copy

В отличие от старой Java и JavaScript нельзя получить memory leak: lifetime `&str` привязан к `String`

char

char

Примитивный тип для хранения Unicode Codepoint, 32 бита

Используется редко: единица текста это grapheme cluster

API знает про Unicode:

```
impl char {
    to_lowercase(self) -> ToLowercase; // итератор!
}

impl Iterator for ToLowercase {
    type Item = char;
}
```

API

```
impl str {
    fn chars(&self) -> Char; // итератор charов

    fn to_ascii_lowercase(&self) -> String;
    fn make_ascii_uppercase(&mut self);

    // нельзя обойтись без аллокации
    fn to_lowercase(&self) -> String;

    // индекс в байтах, можно использовать в `[]`
    pub fn find<'a, P>(&'a self, pat: P) -> Option<usize>
        where P: Pattern<'a>;
    fn is_char_boundary(&self, index: usize) -> bool;

    fn as_bytes(&self) -> &[u8];
}

// std::str
pub fn from_utf8(v: &[u8]) -> Result<&str, Utf8Error>;
```

Цена Абстракции

В Rust есть два представления для последовательностей:

1. слайсы: `[T]`, `str`
2. итераторы: `Iterator<Item = T>`

В теории, должно хватать только итераторов

На практике, знание о том, что объекты лежат в памяти последовательно, позволяет значительно ускорить многие низкоуровневые операции (`memcpy`, `memchr`, etc).

CString / CStr

Многие FFI строки используют `char *` — байты, терминированные `0`

`String` и `str` не совместимы с `char *`: нет нулевого байта в конце, нет гарантии про utf-8

`CString` — обёртка над `char *` для FFI

чтобы превратить `String` в `CString` нужна аллокация

OsString / OsStr

- строки в Unix — последовательность ненулевых байтов
- строки в Windows — "UTF-16" с непарными суррогатами

`OsString` может представить любую строку ОС. Внутреннее представление — WTF-8 (надмножество Unicode для представления невалидный строк)

`String` это `OsString`, `str` это `OsStr`

PathBuf / Path

`PathBuf` обёртка над `OsString` для работы с путями

Интерпретирует `/`, `\` как сепараторы + куча полезных методов

На windows `/` работает в качестве сепаратора

Итоги

Строк много. Любая строка — вектор байт, отличие в инвариантах

owned	String	CString	OsString	PathBuf
borrowed	str	CStr	OsStr	Path

`Os` и `C` варианты — редкие

UTF-8 + байтовые индексы — эффективное низкоуровневое представление